# Deskriptive Auswertung – die interessantesten Auszüge

(Text in der source-File und in dieser Datei ist größtenteils deckungsgleich.)

### 1. Basisstatistik

Skalen der Variablen:

Metric (mehr oder minder): DemAffl, DemAge, DemCluster

Ordinal: DemClusterGroup, PromClass

Nominal: DemGender, DemReg, DemTVReg

# (a) Metrische Variablen

DemAffl, DemAge, PromTime sind genaugenommen ordinal. Z. B. ist für das Alter nicht klar, wie viele Monate/Tage/... die Person alt ist, nur das Jahr ist bekannt. Dennoch wird auch in Studien gerne z. B. das Durchschnittsalter metrisch durch den Mittelwert berechnet. Deshalb behandle ich sie in der Basisstatistik und Korrelationsanalyse als metrisches Daten.

#### Basisstatistik für metrische Variablen

#### Die Prozedur MEANS

Variable	Etikett	N	N Miss	Median	Mittelwert	Std.abw.	Kurtosis	Schiefe	Minimum	Maximum
DemAffl	Affluence Grade	74138	3751	8.0000000	8.7145863	3.4227373	2.0087761	0.8792131	0	34.0000000
DemAge	Age	72618	5271	54.0000000	53.7881517	13.1919180	-0.8386250	-0.0784173	18.0000000	79.0000000
PromSpend	Total Spend	77889	0	2000.00	4430.03	7446.41	158.9498662	7.2976416	0.0100000	296313.85
PromTime	Loyalty Card Tenure	76908	981	5.0000000	6.5554559	4.6568024	8.0292435	2.2746840	0	39.0000000
TargetAmt	Organics Purchase Count	77889	0	0	0.2966786	0.5639145	4.1670831	2.0062726	0	3.0000000

**PromSpend**: Mittelwert und Median liegen weit auseinander. Die Werte weisen darauf hin, dass es nach oben hin mindestens einen Ausreißer geben muss, der den Mittelwert mitzieht. **PromTime**: Obwohl ein Maximalwert von 39 erreicht, wird liegen Median (5) und Mittelwert (ca. 6.56) deutlich darunter. Zu vermuten ist, dass das Programm mehrheitlich Neukunden hat.

Das wird auch bei **TargetAmt** nochmal verdeutlicht, das die Anzahl der eingelösten Gutscheine wiedergibt. Der Median liegt bei 0, der Durchschnitt bei ca. 0.3 .

### (b) Ordinale Variablen

Bei nominalen und ordinalen Variablen ist es inkorrekt, statistische Werte, wie z. B. den Durchschnitt, zu nehmen.

#### Basisstatistik für ordinale Variablen

### Die Prozedur MEANS

Variable	N	N Miss	Median	Minimum	Maximum
age_decade	72618	5271	5.0000000	1.0000000	7.0000000
demAffl_tenth	74138	3751	0	0	3.0000000
promClass_ord	77889	0	1.0000000	0	3.0000000
promSpend_ord	77889	0	2.0000000	0	4.0000000
promTime_quartalized	76908	981	1.0000000	0	13.0000000

**promTime\_quartilized**: Der Median=1 zeigt, dass mindestens die Hälfte der Kunden sich erst im ersten Quartal ihrer Mitgliedschaft befinden.

# (c) Nominale Variablen

Um einen Überblick über deren Verteilung zu bekommen, wird proc freq verwendet.

Gender						
DemGender	Häufigkeit	Prozent				
F	42563	61.63				
М	20395	29.53				
U	6108	8.84				
Häufigkeit Fehlende = 8823						

Organics Purchase Indicator						
TargetBuy	Häufigkeit	Prozent				
0	58465	75.06				
1	19424	24.94				

Es wurde die Häufigkeitstabelle statt des Balkendiagramms gewählt, da diese genauere Auskunft gibt.

**DemGender:** nicht bevölkerungsrepräsentativ, da deutliches Übergewicht der Frauen (61.63 %) und U (unknown oder drittes Geschlecht?, 8.84 %). Daher werden später zufällige Frauen für das Modell aussortiert. Meine lineare Regression hatte aufgrund dessen einen höheren R²-Wert.

**TargetBuy**: Deutliches Übergewicht von 0 (75.06 %). Daher könnte ein Modell lernen, immer 0 vorherzusagen. Deshalb werden später zufällig samples mit Wert 0 aussortiert, sodass 0 und 1 gleichverteilt sind.

# 2. Korrelationsanalyse

a) Metrische Variablen

### Korrelationen zwischen metrischen Variablen

### Die Prozedure CORR

5 Variablen: DemAffl DemAge PromSpend PromTime TargetAmt

Pearsonsche Korrelationskoeffizienten, N = 68306 Prob >  r  unter H0: Rho=0								
	DemAffl	DemAge	PromSpend	PromTime	ΓargetAmt			
DemAffl	1.00000	-0.13696	-0.02684	-0.03086	0.46460			
Affluence Grade		<.0001	<.0001	<.0001	<.0001			
DemAge	-0.13696	1.00000	0.27322	0.20641	-0.30658			
Age	<.0001		<.0001	<.0001	<.0001			
PromSpend	-0.02684	0.27322	1.00000	0.03781	-0.08911			
Total Spend	<.0001	<.0001		<.0001	<.0001			
PromTime	-0.03086	0.20641	0.03781	1.00000	-0.05470			
Loyalty Card Tenure	<.0001	<.0001	<.0001		<.0001			
TargetAmt	0.46460	-0.30658	-0.08911	-0.05470	1.00000			
Organics Purchase Count	<.0001	<.0001	<.0001	<.0001				

Es besteht eine deutliche Korrelation zwischen **DemAffl und TargetAmt** (0.46460). Daher könnte DemAffl im Modell einen starken Einfluss auf die Vorhersagen haben.

Das **DemAge** weist eine negative Korrelation mit dem **TargetAmt** auf (-0.30658). Je höher das Alter, desto weniger eingelöste Gutscheine. Daher könnte auch das Alter ein wichtiges Feature für die Modellvorhersagen sein.

Die metrischen Prädiktorvariablen weisen untereinander keine auffällig starken Korrelationen auf.

# b) Ordinale mit metrischen Variablen

						110 00 00
	DemAffl	DemAge	PromSpend	PromTime	TargetBuy	TargetAmt
DemAffl	1.00000	-0.11045	-0.04511	-0.01526	0.32605	0.34281
Affluence Grade		<.0001	<.0001	<.0001	<.0001	<.0001
DemAge	-0.11045	1.00000	0.41078	0.12763	-0.29557	-0.30090
Age	<.0001		<.0001	<.0001	<.0001	<.0001
PromSpend	-0.04511	0.41078	1.00000	-0.09494	-0.12321	-0.12574
Total Spend	<.0001	<.0001		<.0001	<.0001	<.0001
PromTime	-0.01526	0.12763	-0.09494	1.00000	-0.04169	-0.04171
Loyalty Card Tenure	<.0001	<.0001	<.0001		<.0001	<.0001
TargetBuy	0.32605	-0.29557	-0.12321	-0.04169	1.00000	0.99467
Organics Purchase Indicator	<.0001	<.0001	<.0001	<.0001		<.0001

**DemAge und PromSpend:** Mit einem Wert von 0.41078 lässt sich die Tendenz aufzeigen, dass umso höher das Alter, desto mehr wurde in vorherigen Aktionen ausgegeben.

Wenig überraschend ist der Zusammenhang zwischen den beiden Zielvariablen **TargetBuy und TargetAmt** beinahe perfekt (0.99467). Das Model wird nur TargetBuy beachten, da in

der Aufgabenstellung dies die Zielvariable ist. TargetAmt wird ignoriert, um nicht den Lernprozess zu verfälschen.

# c) Nominale mit metrischen Variablen

Assoziationen messen:

Nominal vs. ordinal/nominal --> ChiSquare;

Nominal vs. nominal --> Cramer's V;

### Assoziationen für nominale und ordinale Variablen

Die Prozedur FREQ

### Statistiken für Tabelle von TargetBuy nach DemGender

Statistik	DF	Wert	Prob
Chi-Quadrat	2	3792.9691	<.0001
Likelihood-Ratio Chi-Quadrat	2	4262.9597	<.0001
Mantel-Haenszel Chi-Quadrat	1	3718.1903	<.0001
Phi-Koeffizient		0.2343	
Kontingenzkoeffizient		0.2282	
Cramers V		0.2343	

Stichprobengröße = 69066 Häufigkeit Fehlende = 8823

WARNING: 11% der Daten fehlen.

# Assoziationen für nominale und ordinale Variablen Die Prozedur FREQ

Statistiken für Tabelle von TargetBuy nach promClass ord

Statistik	DF	Wert	Prob
Chi-Quadrat	3	1005.9198	<.0001
Likelihood-Ratio Chi-Quadrat	3	1013.4221	<.0001
Mantel-Haenszel Chi-Quadrat	1	995.8838	<.0001
Phi-Koeffizient		0.1136	
Kontingenzkoeffizient		0.1129	
Cramers V		0.1136	

Stichprobengröße = 77889

Es liegt eine leichte Assoziation zwischen **TargetBuy und DemGender** vor, was anhand des Cramer's Vs in Höhe von 0.2343 klar wird. Daher scheint ein Geschlecht stärker auf Gutscheineinlösungen anzusprechen. Der Zusammenhang ist jedoch nicht stark ausgeprägt.

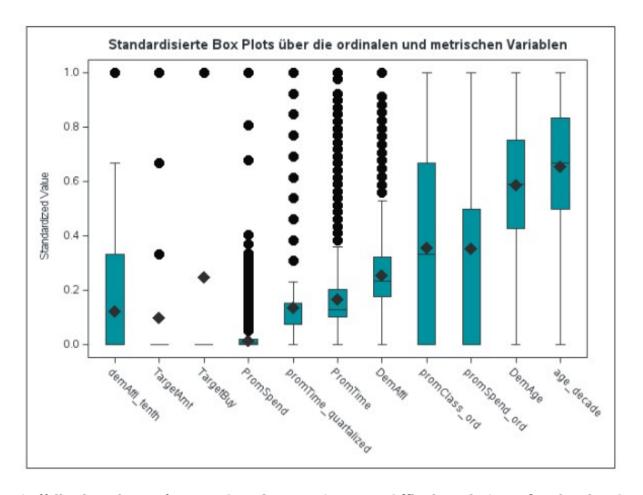
Ein leichter Zusammenhang mit Cramer's V=0.1136 liegt zwischen **TargetBuy und promClass\_ord** (ord für ordinal) vor. Der Statuslevel der Mitgliedschaft scheint auch mit der Bereitschaft, Gutscheine einzulösen, zusammenzuhängen.

Zwischen den Prädiktorvariablen liegen auch hier keine auffälligen Assoziationen vor.

# 3. Boxplot für metrische und ordinale Variablen,

(nominale Variablen sind nicht geeignet)

Alle Variablen werden auf selbes Einheitsmaß gebracht. Hierfür wird das Intervall [0, 1] verwendet. Dadurch lassen sich die Boxplots Seite an Seite darstellen.

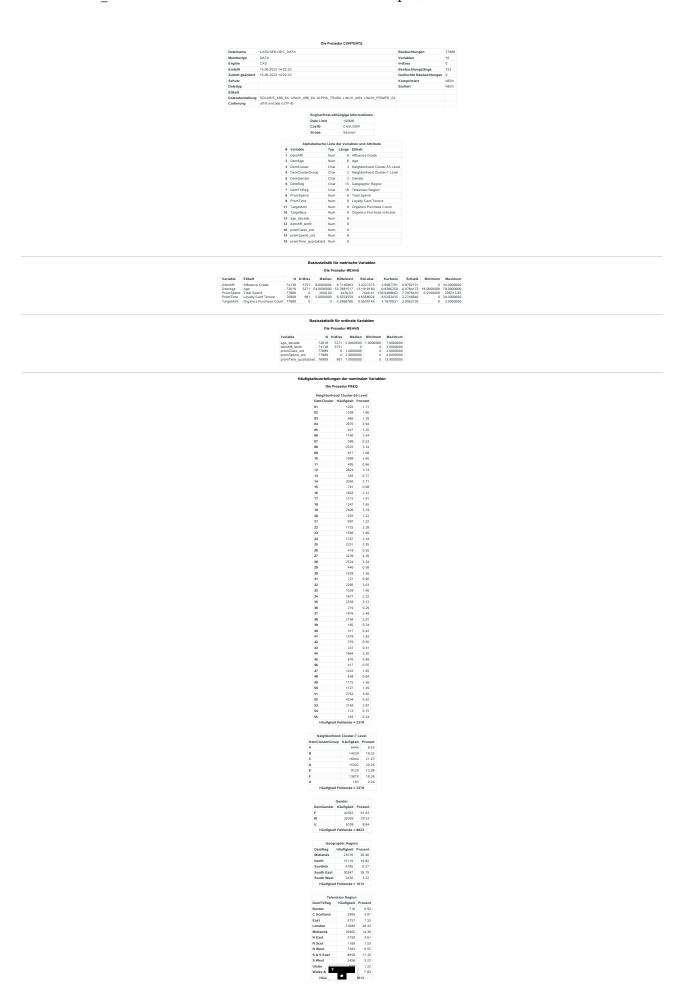


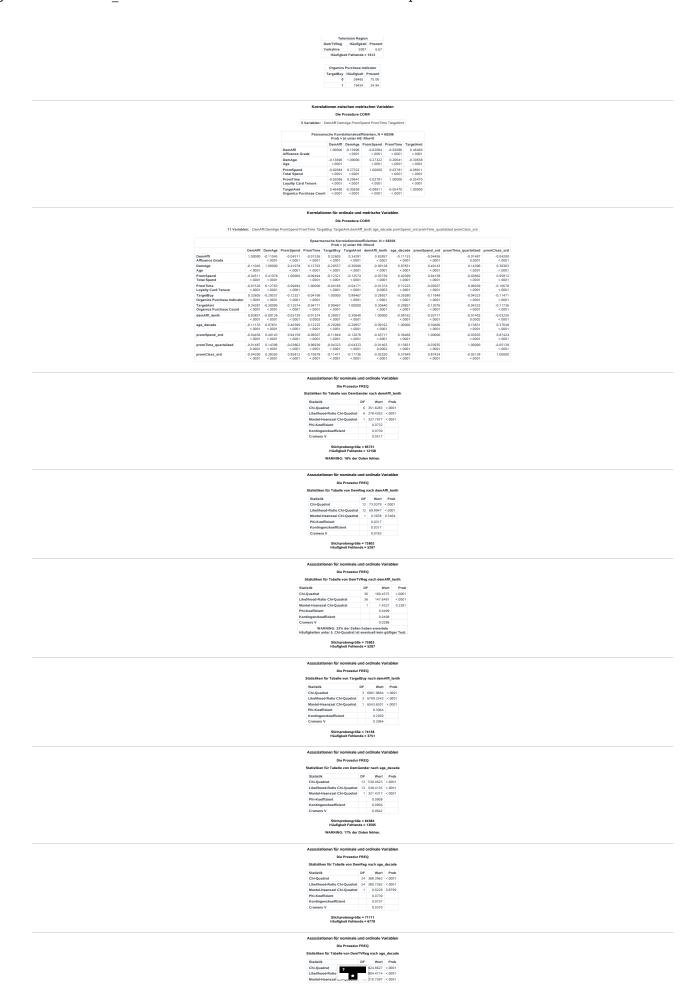
Auffallend ist, dass es für **PromSpend, PromTime, DemAffl** sehr viele Ausreißer über der IQR gibt.

Für **PromSpend** lässt sich dies so interpretieren, dass die meisten Kunden sich anscheinend noch nicht an vorangegangen Aktionen beteiligt hatten.

Auch für **PromTime** wird deutlich, dass die meisten Kunden Neukunden sind. Das könnte als Hinweis dienen, dass die aktuelle Aktion gerade erst anläuft und noch Kunden dazugewinnt.

Alle Ergebnisausgaben der deskriptiven Auswertung als Anfügung:





Statistic
Camers V 0.0466 Sitchprohempidae = 71111 Hidippidae Tehlmida = 478
Associationen für nominale und ordinale Variablen
Dis Prozector PREQ
Likelihod-Ratio Chi-Quadrat 6 9231;1258 < 0.0001
PRACKONTINAN
Sichprobengydise = 72618 Hürlügkeit Fehlende = 5271
Associationen für nominale und ordinale Variablen Die Prozedur FREQ
Statistik         De Wort         Prob           Chalquadrat         4         18122 - 6001
Likelihood-Ratio Chi-Quadrat 4 120592 < 0001  Mantel-Haenszel Chi-Quadrat 1 69065 < 0001
Pibli Cardificat 1.41-02   Kondingens Left Side   0.818150   Camera V   1.00000
Sichprobengride = 6006 Nduligian Feshind = 4823 WARRING: 17% der Daten feshion.
Associationen für nominale und ordinale Variablen Die Prozedur FREQ Stutistikes für Tableit von DemReg nach DemGender
Statistik   DF   Wert   Prob     Chi-Quadrat   8   19.5052   0.0124
Likelihood-Ratio Chi-Quadrat 8 19.3707 0.0130
Mainten-Hermiter En-Quarteri 1   0.0542   0.7/17
Stichperbergrüfe zr 6784 Hürfüger Fellende z 1925 WARRIG 17% der Onles fellen.
Associationen für nominale und ordinale Variablen  Die Presadur (FRE)  Statistiken für Tabelke von Der Villeg nach Demökrerker  Statistiken für Tabelke von Der Villeg nach Demökrerker
Statistik   DF   Wert   Prob     Chi-Quadrat   24   102.2778   0.001
Likalihoo-Kalso Cih-Quastra 1 2 102.795 - 0001 Massi-Hanson Cih-Quastra 1 1 0010 0163 Phi-Xoefffician 0 0039 0
Kontingenskeefflüent 0.039 Camers V 0.0275 Siichoobeeridis = \$V\$34
Sitchproblemgidia et 97414 HJuffgaft Fellomidus e 1925 WARRING: 13% der Daten fiehten.
Associationen für nominale und ordnaie Variablen Die Prosedur FREQ Studistiken für Fabelle von Targettley nach Demdender
Substantia 1 Juni 1 Jun
Mantel-Haenszel Chi-Quadrat 1 3718 1903 < 0001 Phi-Voolfüligint 0.2343
Comment V 2023  Stichgorobengida +0504  Hullgigar Polinete +823
Hausingson Hamminde - 9222 WARNING: 1915, der Oplen fehlen.
Associationer für nominale und ordinale Variablen Die Prezedur FREQ
Statistisk   P   Wort   Prob
Likelinood-katoi Chi-Quadrati         8 19,370 0130           Mantel-Hanssat Chi-Quadrat         1 0,894 0,777           Phi-Koeffizient         0,0170
Kontingensbeeffiziert
Haufigkeit Febinede = 10255 WARRING: 17% der Daten feinten.
Associationen für nominale und ordinale Variablen Die Prezedur PREQ
Statistiken für Tabelle von DemReg rach DemReg           Statistik         Dr. West Prob           Chalquadrat         16 3051618 d.0001
Likelihood-Ratio Chi-Quadrat   12 201614 - 0.001     Manth-Hansarat Chi-Quadrat   7 78275 - 0.001     Phi-Konffilipath   2 0.0000
Manti-Hermanzal Chi-Quadrid   7-8275 c.0001
Häufigkeit Fehlende = 1612
Associationen für nominale und ordinale Variablen Die Prosedur FREQ Slutistike nic Taloile von Dem TVBeg nach DemBeg
Statistik
Likalibos-Ghatio Chi-Quadarii di 201514 d 20011 Mantini-Hamaria Chipodarii di 2025 d 20011 Phi-Gentificant 2,20000 Kontingenta-Gentificant 0,00441
Cramers V 1.00000 Slickprobangida = 79277 Hürligkalir Polinted = 1912
Associationen für nominale und ordinale Variablen
Die Prozedur FREQ Statistiken für Tabelle von Turgelbyn auch Demfleg Statistik DP Wert Prob
Salestia   19
######################################
Sichprobengrifike = 72277 Häufigkeit Pehlunde = 1612
Associationen für nominate und ordinale Variablen Die Prazedur FREQ
Solistation for Tabelle von DemiGrander vach Dest VPReg
Liasilhood-Ballo Cirk-Qualetta 1 2 107.295 - 0.001  Mantahi-Haenzala
C.U.SOY

	Statistik DF Wert Prob Cramers V 0.0225
	Stichprobengride = 67834 Hüfigkeit Fehlende = 10255
	Häufigkeit Fehlende = 10255 WARNING: 13% der Daten fehlen.
	Assoziationen für nominale und ordinale Variablen Die Prozedur FREQ
	Statistiken für Tabelle von DemReg nach DemTVReg
	Staffsilk
	Mantel-Haenszel Chi-Quadrat 1 2225 < 0001
	Phi-K-onfligent 2, 2,0000 Konfligents-keefflident 0, 26443 Cramers V 1,0000
	Cramers V 1,000000 Sichprobengoida = 78277 Hüfüfgkalt Feblanda = 1612
	HJuffgkeit Fehlende = 1612
	Assoziationen für nominale und ordinale Variablen Die Proxedur PREO
	Statistiken für Tabelle von DemTVReg nach DemTVReg
	Statistick OF Word Prob. CM-Qualifold Fide Cold Cold Cold Cold Cold Cold Cold Cold
	Beat Usered City Country 4 27275 - 0001
	Phi-Koeffizient 3.46410 Kontingenzkoeffizient 0.96077
	Siichprobengride = 76277 Häufigkeit Fehlende = 1612
	Assoziationen für nominale und ordinale Variablen
	Die Prozedur FREQ Statistiken für Tabelle von TargetBuy nach DemTVReg
	Statistik DF Wert Prob
	Chi-Quadrat 12 83.5471 < 0.001 Likalihood-Ratio Chi-Quadrat 12 83.599 < 0.001
	Manife-Heavest Chi-Quadrat         1 2 56003 < 0001           Poli-X cofficient         0 0.031           Kontingenskedfildert         0 0.031
	Kontingenzhoeffzient 00331 Cramers V 00331
	Stichprobungsida = 76277 Häufgkeit Fahlande = 1612
	Associationen für nominale und ordinale Variablen Die Prezedur FREQ
Sta	fisition file Tabelle von DemGender nach DemGissterGroup Stateslik DP West Prob CL-Quanter L1 2 56:1389 c.0001
	Statistik         DF         Warf         Prob           Chi-Quadrat         12         5 5.1380         <0001           Likalihood-Ratio Chi-Quadrat         12         05.0337         <0001
	Mantel-Haenszel Chi-Quadrat 1 25.8744 <.0001
	Phil-Confficient 0.0290
	Sitchprobampulia - 46899 HJuffgelt Fellende a 1999 WARNNG: 14% der Daten fehlen.
	Assoziationen für nominale und ordinale Variablen Die Prozedur FREQ
	tatistiken für Tabelle von DemReg nach DemClusterGroup
	Statistik         DF         Wert         Prob           Chi-Quadrat         24         2020.0519         <0001
	Likalihood-Ratio Chi-Quadrat 24 3075.6549 <.0001   Mantel-Hammark Chi-Quadrat 17 11757.0039 <.0001
	PN-K-oefficient 0.1900 Konfingenickoefficient 0.1902 Comers V 0.0905
	Siichprobengričte = 7356 Häufigkeit Fehlende = 3933
	Assoziationen für nominale und ordinale Variablen
State	Die Prozedur FREQ slistiken für Tabelle von DemTVReg nach DemClusterGroup
	(Zeilen und Spalten mit Nullsummen ausgeschlossen)
	Statistik
	Likelihood-Ratio Chi-Quadrat 65 400.7945 < 0.001  Mantel-Haenszel Chi-Quadrat 1 365.7681 < 0.001
	Phi-Koeffizient 0.2428
	Silchprobengröße = 73956 Häufigkeit Fehlende = 3933
	Assoziationen für nominale und ordinale Variablen
	Die Prozedur FREQ
St	atistikan für Tabelle von TargetBuy nach DemClusterGroup
	Statistic
	Mantal Hanneral Chi, Quadrat 1 291 2922 c 0001
	Philosofiguration
	Czamers V 0.0550   0.0550   Sichypokonycida = 73511 Hüfüfgkali Felhinda = 2738
	Häufigkeit Fuhlende = 2378
	Assoziationen für nominale und ordinale Variablen
Si	Die Prozedur FREQ Läfstiken für Tabelle von DemGender nach promClass_ord
	Statistik
	Likelihood-Ratio Chi-Quadrat 6 85.5401 <.0001
	Mantifi-Hanszat Chi-Quadrat
	Cramers V
	Stichprobengröße = 69666 Häufigkeit Fehlende = 8823
	WARNING: 11% der Daten fehlen.
	Assoziationen für nominale und ordinale Variablen Die Prozedur FREQ
	Statistiken für Tabelle von DemReg nach promClass_ord
	Statistik   DF   West   Prob
	Likelihood-Ratio Chi-Quadrat 12 129 9762 < 0001  Mantel-Haenszel Chi-Quadrat 1 4 227461 < 0001
	Phi-Koeffizient 0.0412
	Cramers V 0.0238
	Stichprobangs das = 76277 Häufigkeit Fahlande = 1612

2

Associationen für nominale und ordinale Variablen  Die Presse PREQ  Statistike für Teiler und Deur Wirtige packt prom Class, ord  Statistik Dr wer Prob  Chi-Quadata 15 (242-2416 (2001)  Limitinose Ratio Chi-Quadata 1 (2002)  Mantel-Hausel Chi-Quadata 1 (2003)  Mantel-Hausel Chi-Quadata 1 (2009)  PRE-Konfficient 0 (2071)  Kontingen Konfficient 0 (2071)  Kontingen Konfficient 0 (2077)  Kontingen Konficient 1 (2077)  Stichprobangoide 2-177  National Palance - 11(2)
Associationen für nominate und ordinate Variablen Dur Prozesser PREQ Statistiken für Tarbeit von Targeitigen yacht priem Class, ord  Statistiken für Tarbeit von Targeitigen yacht priem Class, ord  Statistik DF Wert Prob CHC-Quadrat 3 1001-201 (2001) Litherinood-Ratist CHC-Quadrat 1 3 1001-201 (2001) Litherinood-Ratist CHC-Quadrat 1 3 1001-201 (2001) Mantal-Statist CHC-Quadrat 1 3 1011-201 (2001) Mantal-Statist CHC-Quadrat 1 0 1135 Kontingsnodenfürst 0 1129 Cramers V  Stickpochaegelds 7 7389
Associationen für nominale und ordinale Variablen  Die President FREQ  Statistikan für Tabeller von Deminischer sicht princhigend, ord  Statistika für Tabeller von Deminischer sicht princhigend, ord  Statistika für Tabeller von Deminischer sicht princhigend, ord  Statistika für Tabeller von Deminischer sicht sich sicht sicht sicht sicht sicht sicht sicht sich sicht sicht sicht sicht sich
Associationers für nominisate und ordinate Variables  Steistikkun für Takelle von Demilieg auch promSpend_ord  Steistik für Takelle von Demilieg auch promSpend_ord  Steistik für P von P
Stichprobangrida = 76277 Hüdigkait Fehlende = 1612
Associationen für nominale und ordinale Variablen  Der Proseder PEG  Statistik en für Taksits von Targettilsy nach promSpand_ord  Statistik Der West Prob  CHC-Quadrat Der Von Christik CHC-Quadrat (1975) (2015)  CHC-Quadrat CHC-Quadrat (1975) (2015)  Associationen für nominale und ordinale Variablen  Die Proseder PEG  Statistikhe für Taksit verbendinder nach prom Time_quadratiged  CAllen und Spalme mit Multiummen ausgeschlossen  Statistikhe für Taksit (2015) (2005)  Literation-drauf CHC-Quadrat (2015) (2005)  CHC-Quadrat (2015) (2005)  CHC-Quadrat (2015) (2015)  CHC-Quadrat (2015) (2015)  CHC-Quadrat (2015) (2015) (2015)  CHC-Quadrat (2015) (2015) (2015)  CHC-Quadrat (2015) (2015) (2015) (2015)  CHC-Quadrat (2015) (201
Associationen für nominale und ordinale Variablem  Die Prozeete PREQ  Statistiken für Deblie von benehing nach spring mit augustatisted  Statistike für Deblie von benehing nach spring mit augustatisted  Statistike Deblie von benehing nach spring mit augustatisted  Statistike Deblie von benehing nach spring mit augustatisted  Chi-Quadrott S 20 141-242 (2001)  Littlethood-Britist Chi-Quadrott S 20 146-0791 (2001)  Mantes-Hauser Chi-Quadrott S 20 146-0791 (2001)  Philo-Certificient 0 1000)  Kentingsverbendfüllistet 0 1000 (2001)  Crimes V 0 05555
Associationen für nominale und ordinale Variablen
Dia Possedur PREC  Statistiken für Tabelle von Deur Yiller geschip premittine, quaristillerd  Statistike D
American disconnection of contract to an artistic translation
Associationen für nominisale und ordinale Variablen  Der Proseeuer PREQ  Statistiken für Tabelle von Targelfor ynsch premit me, quarelised  Statistiken für Tabelle von Targelfor ynsch premit me, grantingen  Chall-Quariant in der Verscher von Targelfor ynsch premit me, grantingen  Chall-Quariant in der Verscher von Statistiken von St

